

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH



BÁO CÁO TỔNG KẾT

CUỘC THI SINH VIÊN

**NGHIÊN CỨU KHOA HỌC VÀ ĐỔI MỚI SÁNG TẠO
NĂM HỌC 2025-2026**

**TÊN ĐỀ TÀI: NGHIÊN CỨU VÀ XÂY DỰNG
HỆ THỐNG PHIÊN DỊCH HAI CHIỀU GIỮA
NGÔN NGỮ KÍ HIỆU VÀ TIẾNG VIỆT**

Mã số : IT3E_KHSV2526_025

Nhóm trưởng đề tài : MAI NGUYỄN ĐĂNG KHOA

Thời gian thực hiện : Từ tháng 12/2025 đến tháng 3/2026

Thành phố Hồ Chí Minh, tháng 3 năm 2026

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH



BÁO CÁO TỔNG KẾT

CUỘC THI SINH VIÊN

**NGHIÊN CỨU KHOA HỌC VÀ ĐỔI MỚI SÁNG TẠO
NĂM HỌC 2025-2026**

**TÊN ĐỀ TÀI: NGHIÊN CỨU VÀ XÂY DỰNG
HỆ THỐNG PHIÊN DỊCH HAI CHIỀU GIỮA
NGÔN NGỮ KÍ HIỆU VÀ TIẾNG VIỆT**

Mã số : IT3E_KHSV2526_025

DANH SÁCH THÀNH VIÊN:

- 1. Nhóm trưởng: Mai Nguyễn Đăng Khoa – 2251120423**
 - 2. Thành viên: Lê Tuấn Khang – 2251120420**
 - 3. Thành viên: Bùi Trọng Vũ – 2251120132**
 - 4. Thành viên: Vũ Nguyễn Phương – 2251120437**
 - 5. Thành viên: Lê Nguyễn Minh Phúc – 2251120040**
- Giảng viên hỗ trợ: Ths. Nguyễn Ngọc Thạch**

Thành phố Hồ Chí Minh, tháng 3 năm 2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan rằng nghiên cứu “Nghiên cứu và phát triển hệ thống dịch hai chiều giữa ngôn ngữ ký hiệu và ngôn ngữ tự nhiên” là kết quả nghiên cứu và thực hiện của tập thể nhóm. Toàn bộ nội dung trong nghiên cứu được chúng tôi tìm hiểu, xây dựng và phát triển dựa trên kiến thức đã học cùng với các tài liệu tham khảo có nguồn gốc rõ ràng. Những thông tin, số liệu, hình ảnh trích dẫn trong nghiên cứu đều được ghi nguồn theo đúng quy định.

Chúng tôi xin chịu hoàn toàn trách nhiệm về tính trung thực, khách quan cũng như nội dung của nghiên cứu. Nếu phát hiện có sự sao chép, sao lặt hoặc gian lận trong quá trình thực hiện, chúng tôi xin chịu mọi hình thức xử lý theo quy định của nhà trường.

Chúng tôi cam đoan rằng nghiên cứu này chưa từng được công bố hoặc sử dụng cho bất kỳ công trình nghiên cứu nào khác trước đây.

TP. Hồ Chí Minh, ngày 21 tháng 3 năm 2026

Đại diện nhóm thực hiện

Nhóm trưởng đề tài

(Ký và ghi rõ họ tên)

Mai Nguyễn Đăng Khoa

LỜI CẢM ƠN

Để hoàn thành bài nghiên cứu này, chúng tôi đã nhận được sự giúp đỡ và hỗ trợ quý báu từ nhiều cá nhân và tổ chức. Nhóm chúng tôi xin bày tỏ lòng biết ơn sâu sắc tới:

ThS. Nguyễn Ngọc Thạch – giảng viên hỗ trợ, đã tận tình chỉ bảo, kiểm tra và định hướng cho nhóm, chia sẻ những kiến thức quý báu cũng như động viên nhóm trong suốt quá trình thực hiện đề tài đầy thách thức này.

Ban lãnh đạo và quý Thầy/Cô giáo Viện Công nghệ Thông tin và Điện, Điện tử, Trường Đại học Giao Thông Vận Tải Thành phố Hồ Chí Minh đã trang bị cho nhóm nền tảng kiến thức vững chắc để thực hiện bài nghiên cứu này.

Gia đình, bạn bè đã luôn động viên và hỗ trợ chúng tôi trong suốt quá trình học tập và nghiên cứu.

Mặc dù đã cố gắng hết sức thực hiện đề tài, song bài nghiên cứu không tránh khỏi những thiếu sót, chúng tôi rất mong nhận được sự góp ý của quý Thầy/Cô và các bạn đọc để đề tài được hoàn thiện hơn.

TP. Hồ Chí Minh, ngày 21 tháng 3 năm 2026

Đại diện nhóm thực hiện

Nhóm trưởng đề tài

(Ký và ghi rõ họ tên)

Mai Nguyễn Đăng Khoa

DANH SÁCH THÀNH VIÊN

STT	HỌ VÀ TÊN	MÃ SỐ SV	LỚP	KHOA/VIỆN
1	Mai Nguyễn Đăng Khoa	2251120423	CN22H	Viện Công Nghệ Thông Tin và Điện, Điện Tử
2	Lê Tuấn Khang	2251120420	CN22H	Viện Công Nghệ Thông Tin và Điện, Điện Tử
3	Vũ Nguyễn Phương	2251120437	CN22H	Viện Công Nghệ Thông Tin và Điện, Điện Tử
4	Bùi Trọng Vũ	2251120132	CN22B	Viện Công Nghệ Thông Tin và Điện, Điện Tử
5	Lê Nguyễn Minh Phúc	2251120040	CN22A	Viện Công Nghệ Thông Tin và Điện, Điện Tử

MỤC LỤC

LỜI CAM ĐOAN

LỜI CẢM ƠN

DANH SÁCH THÀNH VIÊN

MỤC LỤC ii

DANH MỤC HÌNH ẢNH iii

DANH MỤC BẢNG iv

DANH SÁCH BẢNG CHỮ CÁI VIẾT TẮT v

CHƯƠNG 1: GIỚI THIỆU 1

1.1 Giới thiệu chung 1

1.2 Đặc điểm của Ngôn ngữ Ký hiệu Việt Nam (NNKH/VSL) 1

1.3 Mục tiêu và phạm vi nghiên cứu 2

CHƯƠNG 2: CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN 3

2.1 Sự phát triển của các phương pháp nghiên cứu 3

2.2 Một số công trình tiêu biểu 3

2.3 Khoảng trống nghiên cứu 3

CHƯƠNG 3: PHƯƠNG PHÁP VÀ ĐỀ XUẤT 5

3.1 Kiến trúc tổng thể 5

3.2 Thành phần công nghệ chính 5

CHƯƠNG 4: QUÁ TRÌNH THIẾT KẾ VÀ XÂY DỰNG SẢN PHẨM 6

4.1 Cơ sở lý thuyết 6

4.1.1 Kiến trúc Transformer 6

4.1.2 Graph Attention Network (GAT) 6

4.1.3 Cross-Attention và Temporal Pooling 6

4.1.4 Hàm mất mát và tối ưu hóa 7

4.1.5 Data Augmentation 7

4.2 Quy trình chuyển đổi tiếng Việt sang ngôn ngữ ký hiệu (VN $\rightarrow$ VSL) 7

4.2.1 Quy trình cơ bản 7

4.2.2 Quy trình logic xử lý chi tiết 7

4.3 Quy trình chuyển đổi ngôn ngữ ký hiệu sang tiếng Việt (VSL $\rightarrow$ VN) 8

4.3.1	Quy trình cơ bản	8
4.3.2	Thu thập dữ liệu huấn luyện	8
4.3.3	Trích xuất đặc trưng	8
4.3.4	Huấn luyện mô hình Hand-Aware Transformer	9
4.3.5	Nhận dạng theo thời gian thực	10
4.4	Vai trò then chốt của Emotion Encoding trong NNKH	11
4.4.1	Cơ chế trích xuất và mã hóa cảm xúc khuôn mặt	11
4.4.2	Tích hợp vào feature vector	11
4.5	Cơ chế lựa chọn ứng viên tiềm năng – Pipeline 4 giai đoạn	12
CHƯƠNG 5: THỰC NGHIỆM VÀ KẾT QUẢ		13
5.1	Xây dựng Bộ dữ liệu	13
5.2	Kỹ thuật Tăng cường Dữ liệu	13
5.3	Môi trường và Cấu hình Huấn luyện	13
5.4	Kết quả Huấn luyện	14
5.5	Đánh giá theo Từng Nhãn	14
CHƯƠNG 6: PHÂN TÍCH VÀ ĐÁNH GIÁ		16
6.1	Hiệu năng xử lý thời gian thực	16
6.2	Độ ổn định và tính nhất quán của kết quả	16
6.3	Chất lượng ngữ nghĩa của đầu ra	16
CHƯƠNG 7: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		17
7.1	Kết luận	17
7.2	Hướng phát triển	17

DANH MỤC HÌNH ẢNH

5.1	Lịch sử huấn luyện EfficientNet-B2: Loss và Accuracy trên tập Validation qua 40 epoch. Đường nét đứt đánh dấu thời điểm unfreeze backbone (epoch 10); đường vàng chỉ epoch tốt nhất (epoch 28, Val Balanced Accuracy = 70.7%). . .	14
5.2	Chỉ số Precision, Recall và F1-Score theo từng nhãn cảm xúc trên tập Validation.	14
5.3	Chỉ số Precision, Recall và F1-Score theo từng nhãn cảm xúc trên tập Test. . .	15

DANH MỤC BẢNG

DANH SÁCH BẢNG CHỮ CÁI VIẾT TẮT

STT	Từ viết tắt	Ý nghĩa
1	AR	Thực tế ảo tăng cường – Augmented Reality
2	ASL	Ngôn ngữ Ký hiệu Mỹ – American Sign Language
3	BGR	Không gian màu xử lý ảnh – Blue Green Red
4	BiLSTM	Bộ nhớ Ngắn-Dài hạn Hai chiều – Bidirectional Long Short-Term Memory
5	CNN	Mạng Nơ-ron Tích chập – Convolutional Neural Network
6	CSL	Ngôn ngữ Ký hiệu Trung Quốc – Chinese Sign Language
7	DTW	Độ Cong Thời gian Động – Dynamic Time Warping
8	FER	Nhận diện biểu cảm khuôn mặt – Facial Expression Recognition
9	FFN	Mạng nơ-ron truyền thẳng – Feed Forward Network
10	GAT	Mạng chú ý đồ thị – Graph Attention Network
11	HMM	Mô hình Markov Ẩn – Hidden Markov Model
12	JSON	Định dạng lưu trữ dữ liệu – JavaScript Object Notation
13	LSTM	Bộ nhớ Ngắn-Dài hạn – Long Short-Term Memory
14	MCP	Khớp bàn ngón tay – Metacarpophalangeal
15	NLP	Xử lý Ngôn ngữ Tự nhiên – Natural Language Processing
16	NNKH	Ngôn ngữ Ký hiệu
17	QIPEDC	Bộ dữ liệu ngôn ngữ ký hiệu dành cho giáo dục học sinh khiếm thính cấp tiểu học
18	RGB	Không gian màu xử lý ảnh – Red Green Blue
19	STT	Chuyển đổi giọng nói thành văn bản – Speech-to-Text
20	SVM	Máy Vector Hỗ trợ – Support Vector Machine
21	UI	Giao diện người dùng – User Interface
22	UTH	Trường Đại học Giao thông Vận tải TP. Hồ Chí Minh – University of Transport Ho Chi Minh City
23	VN	Tiếng Việt / Việt Nam
24	VSL	Ngôn ngữ Ký hiệu Việt Nam – Vietnamese Sign Language

CHƯƠNG 1 – GIỚI THIỆU

1.1 Giới thiệu chung

Đề tài **”Nghiên cứu và Phát triển Hệ thống Dịch Hai Chiều giữa Ngôn ngữ Ký hiệu và Ngôn ngữ Tự nhiên”** được thực hiện nhằm xây dựng một nền tảng ứng dụng di động thế hệ mới, hỗ trợ người khiếm thính và khiếm thanh giao tiếp hiệu quả, tự nhiên và bình đẳng hơn trong cuộc sống hàng ngày. Đây là một trong những hướng nghiên cứu có ý nghĩa xã hội sâu sắc, nhằm thu hẹp khoảng cách giao tiếp giữa cộng đồng người khiếm thính và phần còn lại của xã hội Việt Nam.

Theo thống kê, Việt Nam có khoảng 2,5 triệu người khiếm thính, trong đó phần lớn sử dụng Ngôn ngữ Ký hiệu Việt Nam (Vietnamese Sign Language – VSL) như ngôn ngữ mẹ đẻ của mình (Bộ Y tế Việt Nam). Tuy nhiên, do thiếu hụt các công cụ phiên dịch tự động và chính xác, việc giao tiếp giữa họ với những người không biết ngôn ngữ ký hiệu vẫn còn nhiều rào cản.

Hệ thống được đề xuất trong nghiên cứu này được thiết kế để đóng vai trò như một cầu nối thông minh, cho phép chuyển đổi linh hoạt hai chiều giữa cử chỉ ký hiệu, văn bản và giọng nói tiếng Việt.

1.2 Đặc điểm của Ngôn ngữ Ký hiệu Việt Nam (NNKH/VSL)

Ngôn ngữ ký hiệu là một **ngôn ngữ thị giác – không gian** hoàn chỉnh, với ngữ pháp và cú pháp riêng biệt, không phụ thuộc vào tiếng Việt nói hay viết. Trong NKKH, thông tin ngữ pháp được truyền tải đồng thời qua nhiều kênh như: vị trí và chuyển động của tay, hướng lòng bàn tay, biểu cảm khuôn mặt, chuyển động của miệng và môi, cũng như hướng nhìn của người thực hiện ký hiệu.

Một điểm đặc trưng quan trọng là cấu trúc câu trong VSL tuân theo thứ tự rất khác so với tiếng Việt thông thường. Cụ thể, một câu trong VSL thường được xây dựng theo trật tự:

THỜI GIAN → ĐỊA ĐIỂM → CHỦ THỂ → ĐỘNG TÁC → ĐỐI TƯỢNG → (NHÂN MẠNH/KẾT THÚC)

Ví dụ, câu tiếng Việt:

”Hôm nay ở nhà tôi ăn cơm rồi”

sẽ được biểu diễn trong VSL theo chuỗi ký hiệu:

HÔM NAY → NHÀ → TÔI → ĂN → CƠM → (XONG)

Do đó, hệ thống phiên dịch không thể đơn thuần dịch từng từ theo thứ tự ban đầu mà cần phải thực hiện bước phân tích ngữ pháp và tái cấu trúc câu theo quy tắc của VSL. Đây là một trong những thách thức kỹ thuật quan trọng trong việc xây dựng hệ thống phiên dịch tự động giữa ngôn ngữ ký hiệu và tiếng Việt.

1.3 Mục tiêu và phạm vi nghiên cứu

Hệ thống được đề xuất trong nghiên cứu này tập trung vào việc xây dựng một nền tảng phiên dịch hai chiều giữa ngôn ngữ ký hiệu và tiếng Việt, với hai chức năng chính:

- **Chuyển đổi từ ngôn ngữ ký hiệu sang tiếng Việt (VSL $\rightarrow$ VN):** Hệ thống sử dụng camera để ghi nhận chuỗi hình ảnh cử chỉ tay và biểu cảm khuôn mặt của người sử dụng. Sau đó, các mô hình học sâu (Deep Learning) được áp dụng để nhận diện chuỗi ký hiệu và chuyển đổi thành văn bản tiếng Việt.
- **Chuyển đổi từ tiếng Việt sang ngôn ngữ ký hiệu (VN $\rightarrow$ VSL):** Hệ thống phân tích câu tiếng Việt bằng các kỹ thuật xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP), sau đó ánh xạ nội dung sang các ký hiệu tương ứng trong cơ sở dữ liệu và hiển thị dưới dạng video ký hiệu.

Hệ thống ứng dụng các công nghệ trí tuệ nhân tạo hiện đại như *Computer Vision*, *Deep Learning* và *Natural Language Processing* nhằm tạo ra trải nghiệm giao tiếp tự nhiên và thời gian thực. Cách tiếp cận này góp phần thúc đẩy khả năng giao tiếp và hòa nhập xã hội cho cộng đồng người khiếm thính tại Việt Nam.

CHƯƠNG 2 – CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

Lĩnh vực nhận diện và dịch Ngôn ngữ Ký hiệu Việt Nam (VSL) vẫn còn tương đối non trẻ so với các ngôn ngữ ký hiệu phổ biến trên thế giới như Ngôn ngữ Ký hiệu Mỹ (ASL) hay Ngôn ngữ Ký hiệu Trung Quốc (CSL). Phần lớn các nghiên cứu hiện nay vẫn tập trung vào bài toán nhận diện một chiều (VSL $\rightarrow$ văn bản), trong khi các hệ thống dịch hai chiều hoàn chỉnh và thực tế còn rất hạn chế.

2.1 Sự phát triển của các phương pháp nghiên cứu

Các nghiên cứu giai đoạn đầu chủ yếu dựa trên các phương pháp học máy truyền thống như Hidden Markov Model (HMM), Support Vector Machine (SVM) và Dynamic Time Warping (DTW). Tuy nhiên, từ sau năm 2018, sự bùng nổ của Deep Learning đã kéo theo những cải tiến vượt bậc. Các kiến trúc như CNN, LSTM, và Transformer đã được áp dụng rộng rãi và trở thành xu hướng chủ đạo, giúp cải thiện đáng kể độ chính xác và khả năng xử lý chuỗi thời gian trong nhận diện ký hiệu.

2.2 Một số công trình tiêu biểu

- **Vietnamese Sign Language Alphabet Recognition Using MediaPipe và Deep Learning (2025):** Xây dựng bộ dữ liệu gồm 23 chữ cái và 2 dấu thanh của VSL, đạt độ chính xác lên tới khoảng 95%, cho thấy tiềm năng to lớn của MediaPipe trong việc trích xuất đặc trưng bàn tay.
- **Ứng dụng MoViNet-A2 cho nhận diện bảng chữ cái VSL:** Sử dụng dữ liệu từ cảm biến Kinect và mô hình phân loại video, cho thấy tiềm năng của việc xử lý dữ liệu đa chiều trong nhận diện chuỗi cử chỉ liên tục.
- **Dự án dịch ngôn ngữ ký hiệu – SV Đại học Sư phạm Kỹ thuật TP.HCM (Huy chương Đồng 2025):** Xây dựng ứng dụng nhận diện ký hiệu kết hợp NLP và Computer Vision, là minh chứng thực tiễn cho sự quan tâm ngày càng tăng đối với bài toán này tại Việt Nam.

2.3 Khoảng trống nghiên cứu

Mặc dù các công trình trên đạt độ chính xác cao trong việc nhận diện ký hiệu đơn lẻ hoặc bảng chữ cái tĩnh, hầu hết vẫn chưa giải quyết được ba thách thức lớn:

- Sự khác biệt sâu sắc về cấu trúc ngữ pháp giữa VSL và tiếng Việt, đặc biệt khi dịch các câu hội thoại phức tạp.
- Thiếu các bộ dữ liệu lớn, chuẩn hóa và đa dạng về người thực hiện, góc quay, điều kiện ánh sáng.

- Khả năng nhận diện chuỗi cử chỉ liên tục theo thời gian thực trên thiết bị di động có tài nguyên hạn chế.

Đề tài này được xây dựng trên cơ sở nhận diện rõ những khoảng trống trên, từ đó đề xuất một hệ thống tích hợp đa thành phần với kiến trúc Hybrid AI để giải quyết toàn diện cả ba chiều thách thức trên.

CHƯƠNG 3 – PHƯƠNG PHÁP VÀ ĐỀ XUẤT

Hệ thống được xây dựng dựa trên mô hình Hybrid AI, là sự kết hợp chặt chẽ giữa Computer Vision, Deep Learning và Natural Language Processing (NLP) để giải quyết bài toán dịch hai chiều VSL $\leftrightarrow$ Tiếng Việt một cách toàn diện.

3.1 Kiến trúc tổng thể

Hệ thống được phân chia thành hai luồng xử lý độc lập và đối xứng, trong đó mỗi luồng tương ứng với một chiều của bài toán dịch thuật. Cả hai luồng đều chia sẻ lớp trung gian Logic Solving trên server, với thiết bị đầu cuối là ứng dụng di động đóng vai trò tiếp nhận đầu vào và hiển thị đầu ra.

Trong phạm vi của đề tài, hệ thống được triển khai trên nền tảng điện thoại thông minh. Thiết bị này tích hợp sẵn microphone, camera và màn hình hiển thị, cho phép thu nhận dữ liệu đầu vào (giọng nói hoặc video cử chỉ), gửi yêu cầu đến server để xử lý, sau đó nhận kết quả và hiển thị trực tiếp cho người dùng.

Việc sử dụng điện thoại thông minh giúp tận dụng hạ tầng phần cứng phổ biến, giảm chi phí triển khai và tăng khả năng tiếp cận của người dùng, đồng thời vẫn đảm bảo khả năng mở rộng hệ thống sang các thiết bị chuyên dụng (như kính thông minh) trong tương lai.

3.2 Thành phần công nghệ chính

- **MediaPipe (Google):** Thư viện trích xuất điểm mốc (landmark) trên cơ thể và bàn tay với độ chính xác cao và tốc độ xử lý realtime.
- **Transformer:** Mô hình học sâu chính được sử dụng cho bài toán nhận diện và dịch chuỗi cử chỉ theo thời gian (VSL $\rightarrow$ VN). Transformer sử dụng cơ chế Attention giúp mô hình học được mối quan hệ dài hạn giữa các frame trong chuỗi video, từ đó cải thiện độ chính xác so với các mô hình tuần tự truyền thống như RNN hay LSTM.
- **Underthesea:** Thư viện NLP chuyên biệt cho tiếng Việt, dùng để phân tách từ, loại bỏ từ dừng và chuẩn hóa đầu vào (VN $\rightarrow$ VSL).
- **PhoBERT:** Mô hình ngôn ngữ BERT tiền huấn luyện trên tiếng Việt, được dùng để chấm điểm và lựa chọn từ phù hợp nhất về mặt ngữ cảnh.
- **FER-2013 Dataset / Emotion Recognition Model:** Mô hình phát hiện biểu cảm khuôn mặt theo 7 trạng thái cảm xúc, tích hợp vào vector đặc trưng để tăng độ chính xác phiên dịch.

CHƯƠNG 4 – QUÁ TRÌNH THIẾT KẾ VÀ XÂY DỰNG SẢN PHẨM

4.1 Cơ sở lý thuyết

4.1.1 Kiến trúc Transformer

Transformer được áp dụng để xử lý chuỗi đặc trưng tay theo thời gian. Thành phần cốt lõi là Scaled Dot-Product Attention:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (4.1)$$

Multi-Head Attention với $h = 8$ heads, $d_{\text{model}} = 256$, 4 lớp Pre-LayerNorm:

$$\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V), \quad \text{MultiHead} = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (4.2)$$

Positional Encoding mã hóa vị trí frame ($T = 64$):

$$\text{PE}_{(\text{pos}, 2i)} = \sin\left(\frac{\text{pos}}{10000^{2i/d}}\right), \quad \text{PE}_{(\text{pos}, 2i+1)} = \cos\left(\frac{\text{pos}}{10000^{2i/d}}\right) \quad (4.3)$$

4.1.2 Graph Attention Network (GAT)

GAT học quan hệ không gian giữa 6 nhóm ngón tay theo cấu trúc giải phẫu. Ma trận kề chuẩn hóa $\hat{\mathbf{A}} = \mathbf{D}^{-1}(\mathbf{A} + \mathbf{I})$, attention chỉ tính trên cạnh hợp lệ ($h = 4$ heads, $\text{finger_dim} = 32$):

$$\alpha_{ij} = \frac{\exp(s_{ij}) \cdot \hat{A}_{ij}}{\sum_k \exp(s_{ik}) \cdot \hat{A}_{ik}}, \quad \mathbf{h}'_i = \text{LayerNorm}\left(\mathbf{W}^O \sum_j \alpha_{ij} \mathbf{V}_j + \mathbf{h}_i\right) \quad (4.4)$$

4.1.3 Cross-Attention và Temporal Pooling

Cross-Attention hai chiều học quan hệ tay trái $\leftrightarrow$ tay phải:

$$\mathbf{L}' = \text{LayerNorm}(\mathbf{L} + \text{Attention}(\mathbf{L}, \mathbf{R}, \mathbf{R})), \quad \mathbf{R}' = \text{LayerNorm}(\mathbf{R} + \text{Attention}(\mathbf{R}, \mathbf{L}, \mathbf{L})) \quad (4.5)$$

Sau Temporal Transformer, chuỗi được tổng hợp bằng learned attention pooling:

$$w_t = \frac{\exp(\mathbf{h}_t \mathbf{w})}{\sum_{t'} \exp(\mathbf{h}_{t'} \mathbf{w})}, \quad \mathbf{c} = \sum_{t=1}^T w_t \cdot \mathbf{h}_t \quad (4.6)$$

4.1.4 Hàm mất mát và tối ưu hóa

Label Smoothing Cross-Entropy ($\varepsilon = 0.1$, $C = 108$):

$$\mathcal{L} = - \sum_{c=1}^C \tilde{y}_c \log \hat{y}_c, \quad \tilde{y}_c = \begin{cases} 1 - \varepsilon + \varepsilon/C & c = y^* \\ \varepsilon/C & c \neq y^* \end{cases} \quad (4.7)$$

Tối ưu hóa bằng AdamW ($\lambda = 10^{-4}$), Linear Warmup 8 epoch rồi Cosine Decay về $\alpha_{\min} = 10^{-6}$, Early Stopping patience = 20.

4.1.5 Data Augmentation

Tập dữ liệu $108 \times 100 = 10.800$ mẫu, augment 9 lần ($p = 0.4$) bằng Gaussian Noise lên tọa độ tay và đặc trưng curl. Tổng mẫu hiệu dụng: 97.200.

4.2 Quy trình chuyển đổi tiếng Việt sang ngôn ngữ ký hiệu (VN $\rightarrow$ VSL)

Đây là chiều "thuận" của hệ thống, giúp người nghe/nói thông thường có thể truyền đạt thông điệp tới người khiếm thính thông qua thiết bị.

4.2.1 Quy trình cơ bản

Thiết bị thu nhận đầu vào là giọng nói. Tín hiệu âm thanh được chuyển đổi thành văn bản thông qua module STT, tạo thành văn bản thô đại diện cho nội dung người nói muốn truyền đạt. Văn bản này sau đó được gửi lên server để xử lý qua bộ Logic Solving. Phản hồi từ server bao gồm danh sách các từ đã ánh xạ cùng URL video tương ứng, được gửi trả về thiết bị và hiển thị dưới dạng giao diện kèm animation chuyển động 3D hoặc video người ký hiệu thực sự.

4.2.2 Quy trình logic xử lý chi tiết

Khi nhận được văn bản đầu vào (ví dụ: "Tôi xoi cơm với bạn hồi chiều hôm qua"), hệ thống tiến hành qua năm bước xử lý tuần tự:

- **Bước 1 – Chuẩn hóa dữ liệu:** Toàn bộ văn bản được chuyển về chữ thường, loại bỏ dấu câu, ký tự đặc biệt và khoảng trắng thừa. Bước này đảm bảo tính nhất quán khi tra cứu từ điển.
- **Bước 2 – Tách từ (Word Segmentation):** Thư viện Underthesea được sử dụng để phân tách câu tiếng Việt thành các từ/cụm từ có nghĩa. Đây là bước thiết yếu vì tiếng Việt không phân cách từ bằng khoảng trắng như tiếng Anh.
- **Bước 3 – Quét cửa sổ trượt (Sliding Window):** Thay vì dịch từng từ đơn lẻ, hệ thống ưu tiên tìm kiếm các cụm từ dài nhất có trong từ điển ký hiệu trước, rồi dần thu hẹp xuống. Ví dụ, với chuỗi "xoi cơm", hệ thống ánh xạ trực tiếp sang ký hiệu "ăn cơm" thay vì tách thành hai ký hiệu rời rạc, đảm bảo tính tự nhiên và tránh dịch máy móc.

- **Bước 4 – Lọc từ dừng (Stopwords Filtering):** Các từ nối không mang nghĩa thực thể trong ngôn ngữ ký hiệu như ”với”, ”hỏi”, ”của”, ”thì”, ”mà”... nếu không tìm thấy trong từ điển ký hiệu sẽ bị bỏ qua, giúp câu ký hiệu trở nên súc tích và đúng cú pháp VSL hơn.
- **Bước 5 – Sắp xếp lại theo cú pháp VSL:** Các từ/cụm từ đã lọc được sắp xếp lại theo cấu trúc chuẩn của VSL (THỜI GIAN → ĐỊA ĐIỂM → CHỦ THỂ → ĐỘNG TÁC → ĐỐI TƯỢNG), sau đó được ánh xạ sang danh sách URL video tương ứng trong cơ sở dữ liệu và trả về thiết bị để phát.

4.3 Quy trình chuyển đổi ngôn ngữ ký hiệu sang tiếng Việt (VSL → VN)

Đây là chiều ”nghịch” và phức tạp hơn, đòi hỏi hệ thống phải hiểu và giải mã các chuỗi cử chỉ động trong không gian ba chiều từ Quy trình video camera.

4.3.1 Quy trình cơ bản

Thiết bị tiếp nhận Quy trình frames video liên tục từ camera và gửi lên server. Server thực hiện toàn bộ quá trình Logic Solving bao gồm trích xuất đặc trưng, nhận diện cử chỉ, lọc cảm xúc và xử lý ngữ cảnh, sau đó trả về kết quả phiên dịch dưới dạng văn bản và giọng đọc để hiển thị trên giao diện người dùng.

4.3.2 Thu thập dữ liệu huấn luyện

Dữ liệu huấn luyện được thu thập từ webcam theo quy trình có kiểm soát và có cấu trúc. Người thu thập lần lượt chọn nhãn ký hiệu cần quay, chọn trạng thái cảm xúc kết hợp trong số 7 trạng thái được định nghĩa, sau đó thực hiện ký hiệu trong khoảng thời gian tối đa 10 giây trước khi lưu lại. Mỗi phiên quay tạo ra một cặp file gồm video và file metadata đi kèm.

File metadata lưu trữ toàn bộ thông tin ngữ cảnh của video bao gồm trạng thái cảm xúc, mã định danh cảm xúc và ngày cập nhật. Nhờ đó, dữ liệu có thể được truy vết, kiểm tra chất lượng và tái sử dụng một cách dễ dàng. Trong suốt quá trình quay, giao diện hiển thị các điểm mốc bàn tay theo thời gian thực, giúp người thu thập quan sát và điều chỉnh tư thế tay ngay lập tức, đảm bảo chất lượng dữ liệu đầu vào từ đầu.

4.3.3 Trích xuất đặc trưng

Các file video thô được chuyển đổi sang định dạng mảng số để phục vụ huấn luyện mô hình. Quy trình xử lý bao gồm các bước: đọc từng frame của video → đưa qua MediaPipe để phát hiện điểm mốc → chuẩn hóa tọa độ → resample về chuỗi cố định 64 frames → ghép vector cảm xúc one-hot → lưu file với kích thước **(64, 208)**.

Cấu trúc feature vector **208 chiều** cho mỗi frame bao gồm:

- **Pose (45 chiều):** 15 điểm xương quan trọng trên cơ thể (mũi, vai, khuỷu tay, cổ tay, ngón tay cái, hông...), mỗi điểm gồm 3 tọa độ (x, y, z). Dữ liệu được chuẩn hóa bằng cách lấy

điểm giữa hông làm tâm và chia cho khoảng cách giữa hai vai, đảm bảo bất biến về vị trí và kích thước người dùng.

- **Hands (126 chiều):** 21 điểm landmark cho mỗi bàn tay trong không gian 3 chiều ($21 \times 3 \times 2$ tay = 126 chiều). Khi chỉ phát hiện được một tay, hệ thống luôn gán vào slot 0 bất kể trái hay phải. Khi có hai tay, các slot được sắp xếp theo tọa độ x-center (tay bên trái màn hình vào slot 0, bên phải vào slot 1). Tọa độ được chuẩn hóa với gốc tại cổ tay và chia cho khoảng cách MCP-9.
- **Finger Curl (30 chiều):** Mô tả mức độ co duỗi của từng ngón tay trên cả hai bàn tay ($5 \text{ ngón} \times 3 \text{ đặc trưng} \times 2 \text{ tay} = 30 \text{ chiều}$). Mỗi ngón được đặc trưng bởi ba giá trị: *curl_ratio* (tỉ lệ khoảng cách đầu ngón so với cổ tay, 0 = co hoàn toàn, 1 = duỗi thẳng), *bend_angle* (góc gập tại khớp PIP chuẩn hóa, 0 = thẳng, 1 = co tối đa), và *tip_dist_norm* (khoảng cách đầu ngón đến cổ tay, chuẩn hóa theo kích thước bàn tay). Thành phần này cho phép phân biệt các ký hiệu có hình dạng bàn tay tổng thể giống nhau nhưng khác nhau ở trạng thái uốn cong của từng ngón.
- **Emotion (7 chiều):** Vector one-hot encoding biểu diễn 7 trạng thái cảm xúc: Angry (giận dữ), Disgust (ghê tởm), Fear (sợ hãi), Happy (vui vẻ), Sad (buồn bã), Surprise (ngạc nhiên) và Neutral (trung tính). Trạng thái cảm xúc được xác định từ ảnh khuôn mặt thông qua mô hình FER được huấn luyện trên bộ dữ liệu FER-2013.

Để tăng cường dữ liệu, mỗi video gốc được biến thể thành **9 file**: 1 file gốc, 1 file mirror hoán đổi tay trái $\leftrightarrow$ tay phải, 1 file mirror kết hợp nhiễu Gaussian, 2 file thêm nhiễu Gaussian vào tọa độ tay (mức 0.003 và 0.006), 2 file co giãn tỷ lệ tay ($\times 0.95$ và $\times 1.05$), và 2 file time warp (cắt 5% và 10% đầu/cuối). Chiến lược này **chỉ áp dụng cho tập Train**, không áp dụng cho Val và Test, nhằm đánh giá khả năng tổng quát hóa thực sự của mô hình.

4.3.4 Huấn luyện mô hình Hand-Aware Transformer

Mô hình được sử dụng là **HandAwareVSLClassifier** – một kiến trúc Transformer có nhận thức về cấu trúc bàn tay, được thiết kế để khai thác đồng thời quan hệ không gian giữa các ngón tay và quan hệ thời gian giữa các frame. Đầu vào có kích thước **(B, 64, 208)**, được xử lý qua 6 module tuần tự:

- **Feature Parser:** Tách feature vector 208 chiều thành các thành phần riêng biệt – pose (45), tọa độ tay trái (63), tọa độ tay phải (63), curl tay trái (15), curl tay phải (15) và emotion (7) – để xử lý chuyên biệt theo từng loại đặc trưng.
- **Finger Encoder:** Encode từng nhóm ngón tay độc lập (cổ tay và 5 ngón = 6 nhóm) bằng MLP riêng cho mỗi nhóm, tạo ra biểu diễn không gian với *finger_dim* = 32. Cùng một bộ encoder được dùng chung cho cả hai tay.

- **Finger Graph Attention:** Áp dụng Graph Attention Network với ma trận kề phản ánh cấu trúc giải phẫu thực của bàn tay – cổ tay kết nối với 5 ngón, các ngón kề nhau được kết nối. Cơ chế attention chỉ cho phép thông tin truyền qua các cạnh giải phẫu hợp lệ, giúp mô hình học được quan hệ không gian có ý nghĩa sinh học. Chạy độc lập cho tay trái và tay phải với 4 attention heads.
- **Hand Cross Attention:** Cross-attention hai chiều học quan hệ tương tác giữa tay trái và tay phải. Tay trái attend vào tay phải và ngược lại, cho phép mô hình nắm bắt các ký hiệu hai tay phối hợp.
- **Curl Encoder và Hand Aggregator:** Curl Encoder encode đặc trưng co duỗi của từng ngón thành embedding 32 chiều cho mỗi tay. Hand Aggregator sau đó gộp toàn bộ các thành phần – finger embedding, curl embedding, pose và emotion – thành vector **256 chiều** cho mỗi timestep, sẵn sàng đưa vào bước xử lý thời gian.
- **Temporal Transformer:** Transformer encoder với chuẩn hóa trước (pre-norm), 4 lớp và 8 attention heads, xử lý chuỗi 64 timestep để học các phụ thuộc thời gian dài hạn. Positional encoding dạng sinusoidal được thêm vào trước khi đưa vào encoder. Sau Transformer, cơ chế **Temporal Attention Pooling** học trọng số tầm quan trọng của từng frame và tổng hợp thành vector ngữ cảnh toàn cục, cuối cùng được đưa qua bộ phân loại MLP 3 lớp để dự đoán nhãn ký hiệu.

Các siêu tham số chính của mô hình: finger_dim = 32, curl_embed_dim = 32, temporal_dim = 256, temporal_layers = 4, temporal_heads = 8, graph_heads = 4, dropout = 0.2, label smoothing = 0.1, optimizer AdamW với learning rate 5×10^{-4} , warmup tuyến tính 8 epoch, cosine decay và gradient clipping = 1.0.

4.3.5 Nhận dạng theo thời gian thực

Hệ thống nhận dạng theo thời gian thực hoạt động theo vòng lặp liên tục gồm 10 bước: (1) thu frame BGR từ webcam, (2) lật ảnh và chuyển sang RGB, (3) phát hiện điểm mốc bất đồng bộ qua MediaPipe, (4) trích xuất **201 chiều** đặc trưng pose, tọa độ tay và finger curl, (5) chuẩn hóa frame, (6) ghép vector cảm xúc tạo thành vector **208 chiều**, (7) đưa vào buffer cửa sổ trượt, (8) khi đủ 64 frame liên tiếp thì thực hiện suy luận, (9) áp dụng softmax lấy nhãn và điểm tin cậy, (10) kiểm tra tính ổn định trong 3 frame.

Ba cơ chế tối ưu quan trọng được áp dụng:

- **Xử lý bất đồng bộ (MediaPipe LIVE_STREAM mode):** Phát hiện điểm mốc chạy song song với Quy trình thu video thông qua cơ chế callback thread-safe, tránh hiện tượng mất frame kể cả khi tài nguyên phần cứng hạn chế.
- **Bộ đệm cửa sổ trượt (Sliding Window Buffer):** Bộ đệm tự động loại bỏ frame cũ nhất khi thêm frame mới, duy trì cửa sổ quan sát 64 frame gần nhất và cho phép dự đoán liên tục mà không cần chờ kết thúc đoạn cử chỉ hoàn chỉnh.

- **Bộ lọc ổn định (Stability Filter):** Kết quả chỉ được hiển thị khi điểm tin cậy ≥ 0.6 và cùng nhãn xuất hiện trong ít nhất 3 frame liên tiếp. Cơ chế này triệt tiêu hiện tượng nhãn bị giật/nhảy liên tục do nhiễu, đảm bảo trải nghiệm người dùng mượt mà.

4.4 Vai trò then chốt của Emotion Encoding trong NNKH

Một trong những đóng góp quan trọng và đặc sắc nhất của đề tài là việc tích hợp Emotion Encoding vào feature vector. Trong Ngôn ngữ Ký hiệu, biểu cảm khuôn mặt không chỉ là yếu tố thứ cấp mà là một thành phần ngữ pháp bắt buộc, có khả năng thay đổi hoàn toàn ý nghĩa của một cử chỉ.

Ví dụ minh họa: Cùng một cử chỉ tay nhưng khi kết hợp với nét mặt NEUTRAL sẽ có nghĩa là "Cảm ơn" (thông thường), trong khi nét mặt HAPPY biểu đạt "Cảm ơn chân thành" (vui vẻ), nét mặt ANGRY lại dẫn đến ý nghĩa tiêu cực như "Ghét" hoặc sự bức bối, còn SURPRISE truyền đạt sự ngạc nhiên hoàn toàn khác.

Việc thêm 7 chiều emotion vào mỗi timestep (từ 171 lên 178 chiều) không chỉ tăng dung lượng thông tin mà còn cung cấp cho mô hình một lớp ngữ cảnh quan trọng mà các hệ thống chỉ dựa trên nhận diện tay thuần túy hoàn toàn bỏ sót. Đây là điểm phân biệt và tạo ra ưu thế cạnh tranh rõ rệt của hệ thống này so với các công trình trước đó.

4.4.1 Cơ chế trích xuất và mã hóa cảm xúc khuôn mặt

Hệ thống phân tích biểu cảm khuôn mặt dựa trên hai nguồn đầu ra song song từ MediaPipe FaceLandmarker chạy ở chế độ LIVE_STREAM: 468 landmarks tọa độ 3D biểu diễn hình học khuôn mặt, và 52 blendshape coefficients biểu diễn mức độ kích hoạt của từng nhóm cơ mặt theo thang $[0, 1]$.

Module FacialExpressionAnalyzer ưu tiên phân tích theo blendshapes thông qua hàm `analyze_blendshapes()`, tổng hợp các chỉ số chức năng gồm độ mở miệng, nụ cười, độ mở hai mắt, mắt mở to, mắt nheo, và trạng thái lông mày. Các chỉ số này được ánh xạ theo quy tắc ngưỡng sang một trong 7 nhãn cảm xúc chuẩn. Khi blendshapes không khả dụng do điều kiện ánh sáng hoặc góc quay, hệ thống tự động chuyển sang `analyze_landmarks()` — thực hiện phân tích hình học thuần túy từ khoảng cách tương đối giữa các landmarks để ước tính cùng tập chỉ số trên. Cơ chế dự phòng này đảm bảo nhãn cảm xúc được ghi nhận liên tục trong suốt quá trình thu thập.

Tập nhãn cảm xúc gồm 7 lớp được định nghĩa thống nhất qua hằng số EMOTIONS: *angry* (0), *disgust* (1), *fear* (2), *happy* (3), *sad* (4), *surprise* (5), *neutral* (6). Tập nhãn này được dùng xuyên suốt toàn bộ pipeline — từ giao diện chọn nhãn khi thu video (`ask_emotion()`), lưu metadata (`save_video_emotion()`), cho đến nạp dữ liệu huấn luyện trong `video_to_npy.py`.

4.4.2 Tích hợp vào feature vector

Sau khi xác định nhãn cảm xúc, hệ thống thực hiện mã hóa one-hot thành vector 7 chiều và nối vào cuối feature vector chính tại mỗi timestep. Feature vector chính bao gồm 201 chiều từ pose

landmarks, hand landmarks và finger curl. Kết quả là tensor đầu vào cuối cùng có kích thước **208 chiều** $\times T$ timestep, trong đó 7 chiều emotion cung cấp ngữ cảnh biểu cảm bổ sung cho từng khung hình trong chuỗi ký hiệu.

Thông tin emotion được lưu song song với video dưới dạng file .json kèm theo, ghi nhận cả tên nhãn lẫn chỉ số nguyên (emotion_id) để đảm bảo tính tương thích giữa các bước trong pipeline xử lý dữ liệu.

Cách tiếp cận này khác biệt so với các hệ thống CNN nhận diện cảm xúc học từ pixel ảnh khuôn mặt: thay vì xây dựng một nhánh CNN riêng biệt đòi hỏi lượng lớn dữ liệu gán nhãn, hệ thống tận dụng biểu diễn trung gian chất lượng cao của MediaPipe vốn đã được tối ưu hóa trên tập dữ liệu quy mô lớn, nhờ đó giảm đáng kể chi phí huấn luyện trong khi vẫn đảm bảo độ chính xác cần thiết cho bài toán nhận dạng ngôn ngữ ký hiệu.

4.5 Cơ chế lựa chọn ứng viên tiềm năng – Pipeline 4 giai đoạn

Để nâng cao độ chính xác cuối cùng và tính tự nhiên của kết quả phiên dịch, hệ thống áp dụng một pipeline 4 giai đoạn lọc dần từ nhiều ứng viên xuống một kết quả chính xác nhất:

- **Giai đoạn 1 – Mô hình cử chỉ → Top-3:** Mô hình HandAwareVSLClassifier đưa ra 3 từ ứng viên có xác suất cao nhất dựa trên đặc trưng cử chỉ tay và cấu trúc ngón.
- **Giai đoạn 2 – Lọc cảm xúc → Top-2:** Lọc tiếp 3 ứng viên bằng kết quả nhận diện biểu cảm khuôn mặt, loại bỏ các từ không phù hợp với cảm xúc đang biểu đạt, còn lại 2 ứng viên.
- **Giai đoạn 3 – Làm mượt thời gian → Top-2:** Áp dụng làm mượt theo thời gian qua nhiều frame để loại bỏ dự đoán bất thường, giữ lại 2 ứng viên ổn định nhất.
- **Giai đoạn 4 – Chấm điểm ngữ cảnh bằng PhoBERT → Kết quả cuối:** Mô hình ngôn ngữ PhoBERT đánh giá xác suất xuất hiện của từng ứng viên trong ngữ cảnh các từ đã được nhận diện trước đó trong câu, chọn ra từ phù hợp nhất cả về cử chỉ, cảm xúc lẫn ngữ cảnh tiếng Việt.

CHƯƠNG 5 – THỰC NGHIỆM VÀ KẾT QUẢ

5.1 Xây dựng Bộ dữ liệu

Bộ dữ liệu huấn luyện được tổng hợp từ hai nguồn chính. Nguồn thứ nhất là bộ dữ liệu chuẩn QIPEDC do Bộ Giáo dục và Đào tạo ban hành, phục vụ giáo dục học sinh khiếm thính cấp tiểu học. Nguồn thứ hai là dữ liệu tự thu thập thông qua công cụ `webcam_collector.py` được phát triển trong khuôn khổ đề tài.

Quá trình thu thập được thiết kế có chủ đích nhằm đảm bảo tính đa dạng: mỗi từ/cụm từ được quay với đầy đủ 7 trạng thái cảm xúc (angry, disgust, fear, happy, sad, surprise, neutral), thực hiện bởi nhiều người khác nhau trong các điều kiện góc quay và ánh sáng đa dạng. Bộ dữ liệu bao gồm **7 nhãn cảm xúc** với tổng số mẫu phân bố không đồng đều, phản ánh đặc tính tự nhiên của dữ liệu cảm xúc thực tế: smile ($n=1.774$), cry ($n=1.247$), neutral ($n=1.233$), scare ($n=1.024$), angry ($n=958$), surprise ($n=831$) và disgust ($n=111$).

5.2 Kỹ thuật Tăng cường Dữ liệu

Do quy mô dữ liệu thực tế còn hạn chế, đặc biệt ở nhãn disgust ($n=111$), nhóm áp dụng chiến lược tăng cường dữ liệu (data augmentation) để mở rộng tập huấn luyện. Mỗi video gốc được biến thể thành 7 phiên bản thông qua ba nhóm kỹ thuật:

- **Nhiều Gaussian (Gaussian Noise):** Thêm nhiễu ngẫu nhiên ở hai mức độ (0.003 và 0.006) vào tọa độ landmark, mô phỏng sự biến động do điều kiện ánh sáng kém hoặc chất lượng camera thấp.
- **Co giãn tỷ lệ (Scale Jitter):** Nhân tọa độ bàn tay theo hệ số $\times 0.95$ và $\times 1.05$, mô phỏng người dùng đứng ở các khoảng cách khác nhau so với camera.
- **Cắt gọt thời gian (Time Warp):** Cắt 5% và 10% số frame ở đầu và cuối chuỗi, buộc mô hình học cách nhận diện ký hiệu khi được thực hiện ở tốc độ khác nhau.


Đáng lưu ý, kỹ thuật augmentation đóng vai trò đặc biệt quan trọng với nhãn disgust do số lượng mẫu gốc rất hạn chế, giúp tránh hiện tượng mô hình bỏ qua hoàn toàn nhãn thiểu số này trong quá trình học.

5.3 Môi trường và Cấu hình Huấn luyện

Mô hình EfficientNet-B2 được huấn luyện theo chiến lược hai giai đoạn trên framework PyTorch. Ở giai đoạn đầu (epoch 1–9), backbone được đóng băng (frozen) và chỉ huấn luyện lớp phân loại đầu ra, giúp mô hình nhanh chóng hội tụ về đặc trưng bài toán. Từ epoch 10 trở đi, toàn bộ backbone được mở đóng băng (unfreeze) để tinh chỉnh sâu hơn với learning rate nhỏ hơn.

5.4 Kết quả Huấn luyện

Hình 5.1 trình bày biểu đồ biến thiên loss và accuracy trên tập Validation qua 40 epoch huấn luyện. Thời điểm unfreeze backbone (epoch 10) được đánh dấu bằng đường nét đứt, cho thấy sự cải thiện đột biến về cả loss lẫn accuracy ngay sau đó.




Hình 5.1: Lịch sử huấn luyện EfficientNet-B2: Loss và Accuracy trên tập Validation qua 40 epoch. Đường nét đứt đánh dấu thời điểm unfreeze backbone (epoch 10); đường vàng chỉ epoch tốt nhất (epoch 28, Val Balanced Accuracy = 70.7%).


Mô hình đạt kết quả tốt nhất tại **epoch 28** với **Val Balanced Accuracy = 70.7%**. Chỉ số Balanced Accuracy được ưu tiên thay cho accuracy thông thường do bộ dữ liệu mất cân bằng nghiêm trọng giữa các nhãn (disgust chỉ có 111 mẫu so với 1.774 mẫu của smile). Quan sát biểu đồ loss cho thấy train loss tiếp tục giảm xuống 0.45 trong khi val loss ổn định quanh mức 0.90 từ epoch 20 trở đi, phản ánh hiện tượng overfitting nhẹ không thể tránh khỏi do mất cân bằng dữ liệu.

5.5 Đánh giá theo Từng Nhãn

Để phân tích chi tiết hơn, nhóm đánh giá Precision, Recall và F1-Score trên từng nhãn cảm xúc riêng biệt trên cả tập Validation và tập Test.



Hình 5.2: Chỉ số Precision, Recall và F1-Score theo từng nhãn cảm xúc trên tập Validation.



Hình 5.3: Chỉ số Precision, Recall và F1-Score theo từng nhãn cảm xúc trên tập Test.

Kết quả trên tập Test (Hình 5.3) cho thấy sự phân hóa rõ rệt giữa các nhãn. Nhãn **smile** đạt hiệu năng cao nhất với Precision ≈ 0.91 , Recall ≈ 0.85 và F1-Score ≈ 0.88 , phù hợp với việc đây là nhãn có số lượng mẫu lớn nhất ($n=1.774$). Nhãn **surprise** cũng cho kết quả tốt với F1-Score ≈ 0.80 . Ngược lại, nhãn **scare** đạt hiệu năng thấp nhất với F1-Score ≈ 0.55 , mặc dù có số lượng mẫu trung bình ($n=1.024$), cho thấy đây là nhãn khó phân biệt nhất – nhiều khả năng do đặc trưng biểu cảm của “sợ hãi” dễ bị nhầm lẫn với “angry” hoặc “surprise”. Nhãn **disgust** có Recall cao bất thường (≈ 0.83) so với Precision (≈ 0.61), cho thấy mô hình có xu hướng dự đoán quá nhiều vào nhãn này – hệ quả trực tiếp của việc số lượng mẫu gốc quá ít ($n=111$) dù đã qua augmentation.

Đáng chú ý, kết quả giữa tập Validation (Hình 5.2) và tập Test (Hình 5.3) gần như đồng nhất, cho thấy mô hình tổng quát hóa tốt và không bị overfitting đặc thù trên tập Validation.

CHƯƠNG 6 – PHÂN TÍCH VÀ ĐÁNH GIÁ

6.1 Hiệu năng xử lý thời gian thực

Một trong những yêu cầu phi chức năng quan trọng nhất của hệ thống là khả năng phản hồi gần như tức thì. Để đạt được điều này, hệ thống tối ưu theo nhiều chiều:

- **Xử lý bất đồng bộ:** MediaPipe chạy ở LIVE_STREAM mode với `detect_async()`, tách biệt hoàn toàn luồng capture video và luồng phát hiện landmark. Kỹ thuật thread-safe với `Lock()` đảm bảo không có race condition khi callback trả về kết quả.
- **Vector hóa đặc trưng:** Mỗi frame được nén thành vector 178 chiều số thực thay vì xử lý pixel thô, giảm đáng kể khối lượng dữ liệu truyền lên server và thời gian inference của mô hình.
- **Sliding Window Buffer:** Cơ chế deque(maxlen=64) đảm bảo hệ thống luôn sẵn sàng dự đoán với 64 frame gần nhất mà không cần chờ kết thúc một đoạn cử chỉ hoàn chỉnh.

6.2 Độ ổn định và tính nhất quán của kết quả

Hệ thống tích hợp Stability Filter với hai tiêu chí lọc song song: ngưỡng confidence tổng hợp ($\text{Gesture} + \text{Emotion} + \text{Context} \geq 0.6$) và tính nhất quán thời gian (cùng nhãn trong ≥ 3 frame liên tiếp). Cơ chế kép này giúp loại bỏ hiệu quả cả hai loại lỗi phổ biến: dự đoán sai do nhiễu nhất thời và dự đoán có độ tin cậy thấp.

6.3 Chất lượng ngữ nghĩa của đầu ra

Việc tích hợp PhoBERT Context Scoring ở giai đoạn cuối của pipeline đảm bảo rằng từ được chọn không chỉ phù hợp về cử chỉ và cảm xúc mà còn tự nhiên trong ngữ cảnh câu tiếng Việt. Cơ chế "Bổ sung từ cho tròn nghĩa" tiếp theo giúp câu dịch vượt qua dạng liệt kê từ khóa thô, trở thành câu văn hoàn chỉnh và tự nhiên. Ví dụ, từ chuỗi từ khóa ["Tôi", "xơi cơm", "bạn", "chiều", "hôm qua"], hệ thống tổng hợp thành "Tôi ăn cơm với bạn chiều hôm qua".

CHƯƠNG 7 – KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã nghiên cứu và xây dựng thành công một hệ thống dịch hai chiều toàn diện giữa Ngôn ngữ Ký hiệu Việt Nam (VSL) và tiếng Việt, góp phần thiết thực vào mục tiêu xóa bỏ rào cản giao tiếp cho cộng đồng người khiếm thính. Các kết quả trọng tâm đã đạt được bao gồm:

- Làm chủ công nghệ nhận diện đa thành phần với feature vector 178 chiều (Pose + Hands + Finger Curl + Emotion), đặc biệt là việc tích hợp thành công 7 chiều Emotion Encoding – yếu tố quyết định giúp phân biệt các ký hiệu đồng hình trong VSL.
- Xây dựng hoàn chỉnh hai luồng xử lý: Chiều VSL → VN với mô hình Transformer + Attention + PhoBERT, và chiều VN → VSL với NLP Pipeline sử dụng Underthesea, Sliding Window và cơ sở dữ liệu video ký hiệu.
- Đạt hiệu suất thời gian thực nhờ bộ đệm cửa sổ trượt, xử lý bất đồng bộ MediaPipe và Stability Filter với confidence scoring tổng hợp.
- Đóng góp quy trình thu thập và tăng cường dữ liệu VSL có cấu trúc, kết hợp 7 trạng thái cảm xúc, tạo ra bộ dữ liệu đa dạng và giàu ngữ nghĩa hơn các công trình trước đây.

7.2 Hướng phát triển

Nhóm nghiên cứu định hướng mở rộng và hoàn thiện hệ thống theo các trục chính:

- **Mở rộng quy mô bộ dữ liệu:** Hướng tới bộ dữ liệu VSL trên 10.000 từ vựng, bao gồm cụm từ chuyên ngành, phương ngữ vùng miền và đa dạng hơn về người thực hiện, điều kiện thu thập.
- **Nâng cấp kiến trúc mô hình:** Nghiên cứu áp dụng kiến trúc Transformer thuần túy (Vision Transformer, Temporal Transformer) hoặc Multimodal Learning để khai thác tốt hơn mối quan hệ giữa cử chỉ, cảm xúc và ngữ cảnh.
- **Tối ưu hóa cho thiết bị nhúng:** Áp dụng các kỹ thuật model compression (quantization, pruning) để triển khai mô hình trực tiếp trên kính thông minh hoặc điện thoại di động, giảm phụ thuộc vào kết nối server.
- **Tích hợp công nghệ mới:** Phát triển tính năng hội thoại video thời gian thực với phụ đề tự động, tích hợp Thực tế ảo tăng cường (AR) để học ký hiệu tương tác, và Text-to-Speech đa ngôn ngữ để hỗ trợ giao tiếp quốc tế.
- **Triển khai xã hội:** Hợp tác với các trường chuyên biệt, bệnh viện và cơ quan hành chính để đưa hệ thống vào ứng dụng thực tiễn, đóng góp trực tiếp cho mục tiêu bình đẳng giao tiếp và hòa nhập xã hội cho người khiếm thính Việt Nam.

Hệ thống được kỳ vọng sẽ không chỉ là một công cụ dịch thuật đơn thuần mà còn trở thành nền tảng công nghệ thiết yếu, góp phần kiến tạo một xã hội hòa nhập, bình đẳng và không rào cản giao tiếp cho hơn 2,5 triệu người khiếm thính tại Việt Nam.

TÀI LIỆU THAM KHẢO

- [1] Báo Tiền Phong Sinh viên Việt Nam. *Dự án dịch ngôn ngữ ký hiệu của sinh viên Đại học Sư phạm Kỹ thuật TP.HCM (Huy chương Đồng 2025)*. <https://svvn.tienphong.vn>
- [2] Bộ Giáo dục và Đào tạo Việt Nam. *Bộ dữ liệu Ngôn ngữ ký hiệu dành cho giáo dục học sinh khiếm thính cấp tiểu học (QIPEDC)*. <https://qipcdc.moet.gov.vn>
- [3] Tạp chí Khoa học Đại học Mở TP.HCM. *Ứng dụng mạng MoViNet-A2 cho bài toán nhận diện ký hiệu Tiếng Việt*. <https://journalofscience.ou.edu.vn/index.php/tech-vi/article/view/4201>
- [4] Journal of Science and Technology. *Vietnamese Sign Language Recognition Using Deep Learning and MediaPipe*. <https://jst.vn/index.php/ssad/article/view/56>
- [5] Trường Đại học Khoa học và Công nghệ Hà Nội. *Nghiên cứu và phát triển phương pháp tiếp cận dựa trên cấu trúc và thống kê trong dịch tự động ngôn ngữ ký hiệu Việt Nam*. <https://gust.edu.vn/media/30/uftai-ve-tai-day30075.pdf>
- [6] Kaggle. *FER-2013 Dataset – Emotion Detection*. <https://www.kaggle.com/datasets/msambare/fer2013>